

Proyecto Integrador

Arquitectura Deep Learning para detectar Alcohol Use Disorder (AUD) desde EEG: Biomarcadores Espectrales y Redes de Coherencia Cerebral

Asesor de la empresa: Dr. Gildardo Sánchez Ante

Equipo 38

Carlos Daniel Morales Torres	A01796068
Daniel Castillo de Regil	A01796091
Edgar Gerardo Rojas Medina	A00840712



Maestría en
Inteligencia
Artificial
(MNA)

Actividad 3
Análisis
exploratorio

Introducción:

El presente documento describe el Análisis Exploratorio de Datos (EDA) realizado sobre el posible conjunto de datos de electroencefalografía (EEG) asociado a distintos trastornos psiquiátricos, que se usará para el proyecto integrador del equipo 38. El objetivo de este EDA es comprender la estructura, calidad y características principales de los datos, así como justificar las decisiones de preprocesamiento necesarias para su uso posterior en modelos de aprendizaje automático.

El análisis se centra en técnicas estadísticas descriptivas y visualización de datos, abordando aspectos como valores faltantes, presencia de valores atípicos, distribución de variables, cardinalidad de variables categóricas y balance de clases.

Descripción general del conjunto de datos:

El conjunto de datos utilizado contiene información de EEG preprocesada y variables demográficas/diagnósticas.

- **Número de registros:** 945
- **Número de variables:** 1,149

“Posterior se buscará nutrir la base con mayor número de registros”.

Las variables pueden agruparse en dos grandes categorías:

1. **Variables clínicas y demográficas**, como sexo, edad, nivel educativo, coeficiente intelectual y diagnóstico.
2. **Variables EEG**, que incluyen potencia espectral por banda y electrodo (prefijo AB) y medidas de coherencia entre pares de electrodos.

La alta dimensionalidad del conjunto de datos justifica el uso de técnicas de regularización y selección/reducción de características en etapas posteriores del proyecto.

Análisis de valores faltantes:

Se evaluó la presencia de valores faltantes en el conjunto de datos, los resultados muestran dos puntos en específico:

- Las variables **education** e **IQ** presentan valores faltantes, (15 y 13 respectivamente)
- Las variables EEG no presentan valores faltantes.

El patrón de ausencia sugiere que los valores faltantes se concentran en variables demográficas y no siguen un patrón dependiente de las variables EEG. Por esta razón, se justifica la imputación por la mediana para estas variables, acompañada de la posible inclusión de indicadores binarios de ausencia.

Estadísticas descriptivas:

Se calcularon estadísticas resumidas (media, desviación estándar, valores mínimo y máximo) para las variables numéricas.

Este análisis permitió observar:

- Rangos amplios en variables EEG, consistentes con la naturaleza de señales neurofisiológicas.
- Variabilidad considerable en edad, educación e IQ, lo cual es esperable en una población clínica heterogénea.

Las estadísticas descriptivas proporcionan una primera aproximación a la dispersión y escala de los datos, lo cual es relevante para decisiones de normalización.

Podemos observar como se ven las estadísticas descriptivas de la base de datos, de las principales características, incluyendo el socio demográficas.


	no.	age	education	IQ	AB.A.delta.a.FP1	AB.A.delta.b.FP2	AB.A.delta.c.F7	AB.A.delta.d.F3	AB.A.delta.e.Fz	AB.A.delta.f.F4
count	945.000000	945.000000	930.000000	932.000000	945.000000	945.000000	945.000000	945.000000	945.000000	945.000000
mean	473.000000	30.594804	13.438710	101.580472	20.182936	21.177584	17.749553	18.901698	20.447079	19.490329
std	272.942302	11.781592	2.550461	17.022414	11.282022	12.230662	10.003598	9.079482	9.742912	9.252500
min	1.000000	18.000000	0.000000	49.000000	3.272260	3.244199	3.050507	3.412618	5.066593	4.048931
25%	237.000000	21.730000	12.000000	91.000000	12.784872	13.019269	11.134327	12.460586	13.548645	12.637717
50%	473.000000	26.150000	13.000000	102.000000	17.065286	17.838251	15.541469	16.733004	18.065276	17.432568
75%	709.000000	35.450000	16.000000	114.000000	24.492760	25.654394	21.623961	23.347900	25.573096	23.956748
max	945.000000	71.880000	20.000000	145.000000	92.826192	101.515687	91.373456	82.544167	101.566662	77.197502

En específico observamos en la investigación del dataset, que las variables de las bandas tienen las siguientes especificaciones:

Banda	Rango típico (Hz)
delta	~0.5–4
theta	~4–8
alpha	~8–13
beta	~13–30
highbeta	~20–30
gamma	>30


A su vez, observamos la distribución de los desórdenes, ya que en específico tenemos la meta de analizar y detectar Alcohol Use Disorder (AUD).

Observamos que el desorden con la mayor frecuencia en la base es la depresión, por su lado el AUD se encuentra en el número 4, por lo cual se analizará si agregar otro desorden al análisis o mantenernos con el AUD.



Análisis de valores atípicos:

Mediante diagramas boxplots se identificaron valores atípicos en variables demográficas como edad, educación e IQ.



Estos valores no se consideran errores de medición, sino observaciones clínicas plausibles. Por lo tanto, No se eliminaron valores atípicos y se optará por técnicas de escalado y modelos robustos para mitigar su impacto.

Cardinalidad de variables categóricas:

Se analizó la cardinalidad de las principales variables categóricas: sex, main.disorder, specific.disorder.



```
sex
sex
M    601
F    344
Name: count, dtype: int64
----
main.disorder
main.disorder
Mood disorder                266
Addictive disorder           186
Trauma and stress related disorder 128
Schizophrenia                117
Anxiety disorder            107
Healthy control              95
Obsessive compulsive disorder 46
Name: count, dtype: int64
----
specific.disorder
specific.disorder
Depressive disorder          199
Schizophrenia                117
Healthy control              95
Alcohol use disorder          93
Behavioral addiction disorder 93
Bipolar disorder             67
Panic disorder               59
Posttraumatic stress disorder 52
Social anxiety disorder       48
Obsessive compulsitve disorder 46
Acute stress disorder         38
Adjustment disorder           38
Name: count, dtype: int64
----
```

Todas presentan baja cardinalidad, con un número limitado de categorías claramente definidas. Esto permite su codificación mediante técnicas estándar como *one-hot encoding* o codificación binaria, sin riesgo significativo de explosión dimensional adicional.

Distribución de variables y sesgo:

El análisis de las distribuciones de las variables permitió identificar comportamientos heterogéneos entre las variables demográficas y las variables EEG. En el caso de variables como la edad, se observa una distribución relativamente concentrada, con ligeros sesgos que reflejan la composición real de la población clínica incluida en el estudio. Estas características no representan una limitación significativa, pero sí deben considerarse al interpretar resultados y al definir esquemas de validación.

Por otro lado, las variables EEG, tanto de potencia espectral como de coherencia, muestran distribuciones claramente asimétricas y alejadas de una distribución normal. Este comportamiento es consistente con la naturaleza de los biomarcadores neurofisiológicos, donde es común encontrar colas largas y concentraciones de valores en rangos específicos. Esta observación justifica la aplicación de técnicas de estandarización y, en algunos casos, transformaciones no lineales, con el objetivo de homogeneizar escalas y facilitar el entrenamiento de modelos de aprendizaje automático sin introducir supuestos de normalidad que no se cumplen en los datos.




Análisis de correlación:

Se evaluó la correlación entre un subconjunto representativo de variables EEG.

Los resultados muestran correlaciones elevadas entre algunas variables, lo cual es consistente con la redundancia esperada en características espectrales y de conectividad. Esto respalda la necesidad de:

- Regularización.
- Selección de características.
- Técnicas de reducción de dimensionalidad.



Conclusiones del EDA:

El análisis exploratorio de datos permitió comprender la estructura y calidad del conjunto de datos,

confirmando que se trata de un dataset de alta dimensionalidad con un número moderado de registros, aunque quizá mediante otros datasets podamos hacer crecer la base de datos y que sea adecuado para un modelo de aprendizaje supervisado. Los valores faltantes se concentran únicamente en variables demográficas y pueden manejarse mediante imputación robusta sin afectar las variables EEG, las cuales se encuentran completas.

Se identificaron valores atípicos clínicamente plausibles, así como distribuciones sesgadas en muchas variables EEG, lo que justifica el uso de técnicas de estandarización y modelos regularizados. Las variables categóricas presentan baja cardinalidad y el análisis de la variable objetivo mostró un desbalance moderado de clases, lo que respalda el uso de métricas de evaluación robustas y validación estratificada. En conjunto, el EDA confirma que los datos son consistentes y adecuados para continuar con las etapas de preprocesamiento y modelado, aunque requerimos el acercamiento de un médico para la mayor comprensión de las variables médicas.

Referencias

- Pan American Health Organization. (n.d.). *Alcohol*. <https://www.paho.org/en/topics/alcohol>
- Ramírez-Toscano, Y., et al. (2023). *Patrones de consumo de alcohol en adolescentes y adultos mexicanos: Ensanut Continua 2022*. Instituto Nacional de Salud Pública. <https://ensanut.insp.mx/encuestas/ensanutcontinua2022/doctos/analiticos/11-Consumo.de.alcohol-ENSANUT2022-14817-72323-2-10-20230619.pdf>
- Studer, S., Bui, T. B., Drescher, C., Hanuschkina, A., Winkler, L., Peters, S., & Müller, K.-R. (2020). *Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology*. arXiv. <https://arxiv.org/abs/2003.05155>
- World Health Organization. (2024, June 28). *Alcohol*. <https://www.who.int/news-room/fact-sheets/detail/alcohol>
- World Health Organization. (2024, June 25). *Over 3 million annual deaths due to alcohol and drug use, majority among men*. <https://www.who.int/news/item/25-06-2024-over-3-million-annual-deaths-due-to-alcohol-and-drug-use-majority-among-men>